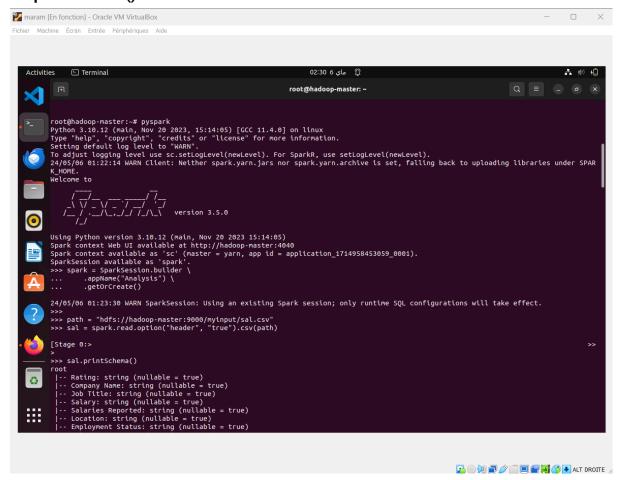
Code SPARK 1/ code scala:

1. Charger le fichier CSV et afficher le schéma des données :

val path = "hdfs://hadoop-master:9000/myinput/sal.csv"
val sal = spark.read.option("header", "true").csv(path)
sal.printSchema()

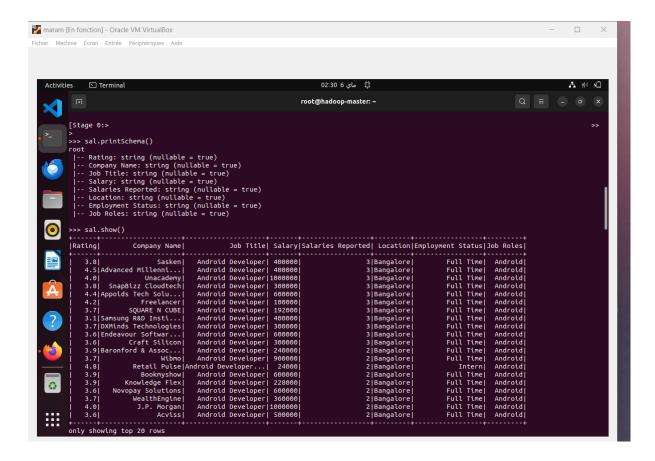


description:Cette commande charge le fichier CSV depuis HDFS dans un DataFrame Spark appelé sal et affiche le schéma des données, montrant les noms des colonnes et leurs types.

2. Afficher les premières lignes du DataFrame :

sal.show()

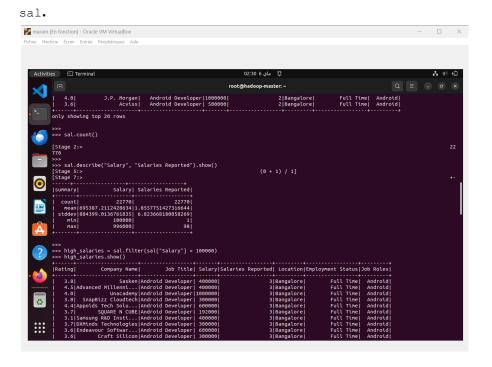
description: Cela affiche les premières lignes du DataFrame sal.



3. Compter le nombre total de lignes dans le DataFrame :

sal.count()

description: Cette commande compte le nombre total de lignes dans le DataFrame



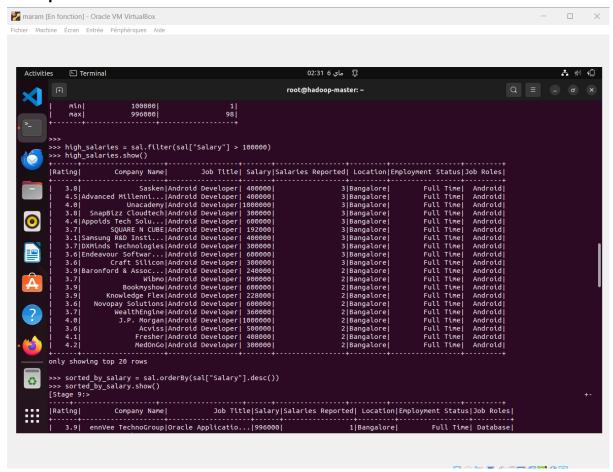
4. Afficher des statistiques descriptives pour les colonnes "Salary" et "Salaries Reported" :

sal.describe("Salary", "Salaries Reported").show()
description:Cela affiche des statistiques descriptives telles que la moyenne, l'écart
type, le minimum, le maximum, etc., pour les colonnes spécifiées.

5. Filtrer les lignes avec un salaire supérieur à 100 000 :

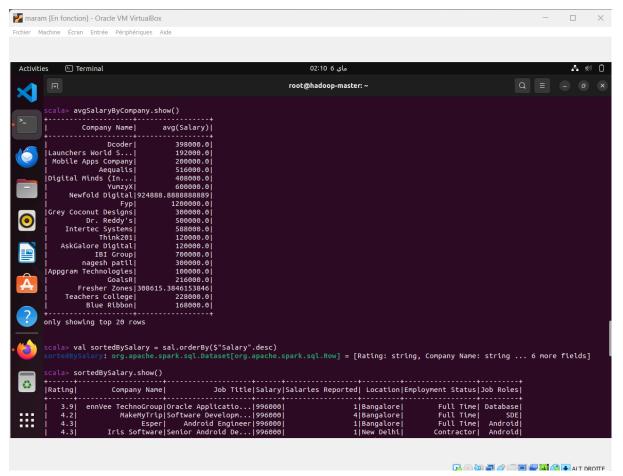
val highSalaries = sal.filter(\$"Salary" > 100000)
highSalaries.show()

description:Cela filtre les lignes du DataFrame où la valeur de la colonne "Salary" est supérieure à 100 000 et affiche le résultat.



6. Calculer le salaire moyen par entreprise :

val avgSalaryByCompany = sal.groupBy("Company Name").avg("Salary")
avgSalaryByCompany.show()

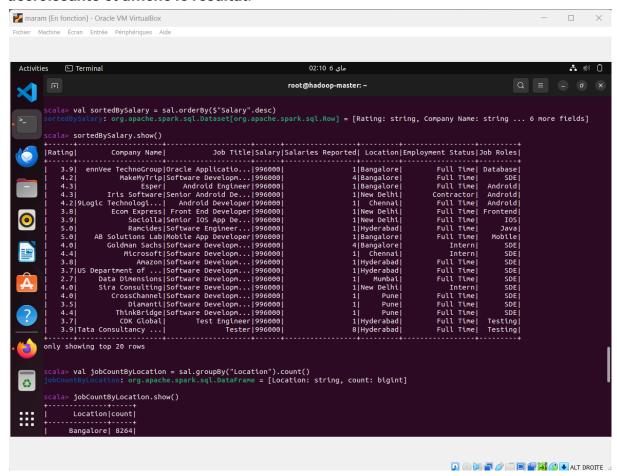


description:Cela regroupe les données par entreprise et calcule la moyenne du salaire pour chaque entreprise, puis affiche le résultat.

7. Trier le DataFrame par salaire décroissant :

val sortedBySalary = sal.orderBy(\$"Salary".desc)
sortedBySalary.show()

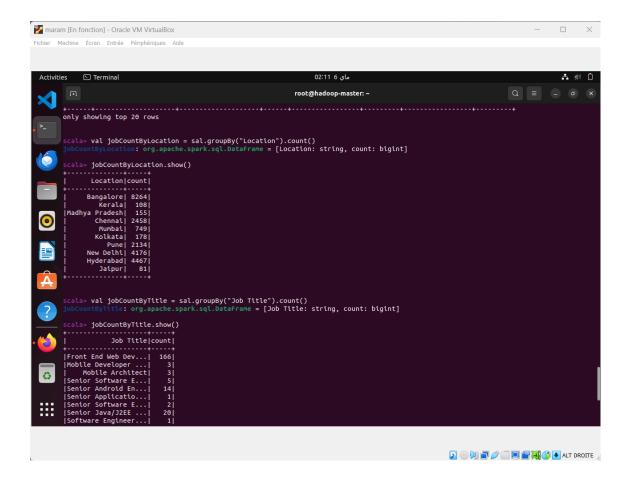
description:Cela trie le DataFrame en fonction de la colonne "Salary" de manière décroissante et affiche le résultat.



8. Compter le nombre d'emplois par emplacement :

val jobCountByLocation = sal.groupBy("Location").count()
jobCountByLocation.show()

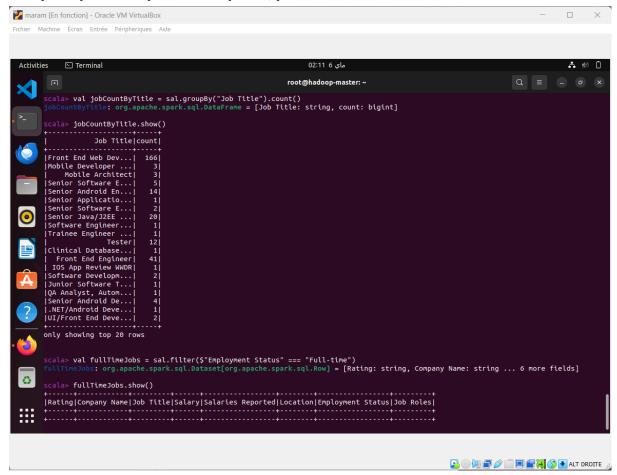
description:Cela regroupe les données par emplacement et compte le nombre d'emplois pour chaque emplacement, puis affiche le résultat.



9. Compter le nombre d'emplois par titre de poste :

val jobCountByTitle = sal.groupBy("Job Title").count()
jobCountByTitle.show()

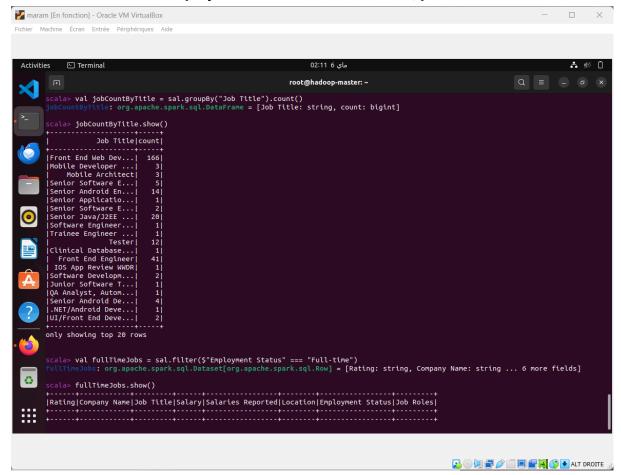
description: Cela regroupe les données par titre de poste et compte le nombre d'emplois pour chaque titre de poste, puis affiche le résultat.



10. Filtrer les emplois à temps plein :

val fullTimeJobs = sal.filter(\$"Employment Status" === "Full-time")
fullTimeJobs.show()

description:Cela filtre les emplois à temps plein en sélectionnant les lignes où la valeur de la colonne "Employment Status" est "Full-time", puis affiche le résultat.



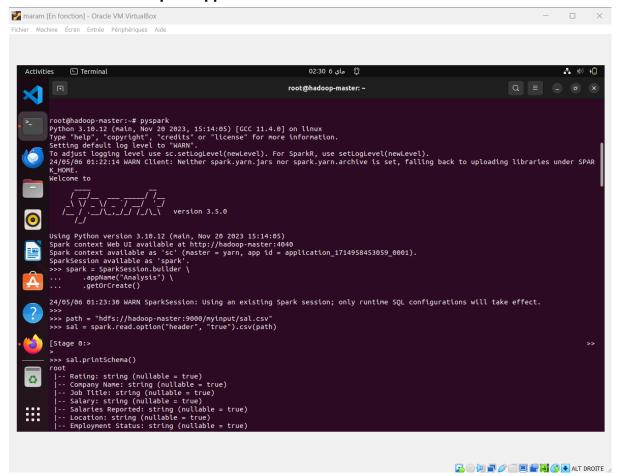
1/ code pyspark:

1. Créer une session Spark et charger le fichier CSV :

from pyspark.sql import SparkSession

```
spark = SparkSession.builder \
          .appName("Analysis") \
          .getOrCreate()
path = "hdfs://hadoop-master:9000/myinput/sal.csv"
sal = spark.read.option("header", "true").csv(path)
```

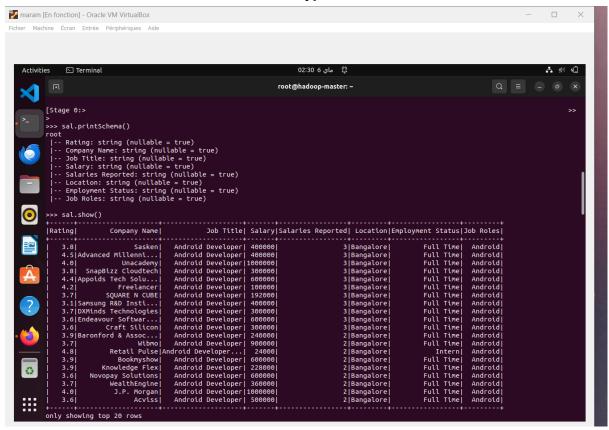
description : Cela crée une session Spark et charge le fichier CSV depuis HDFS dans un DataFrame Spark appelé sal.



2. Afficher le schéma des données :

sal.printSchema()

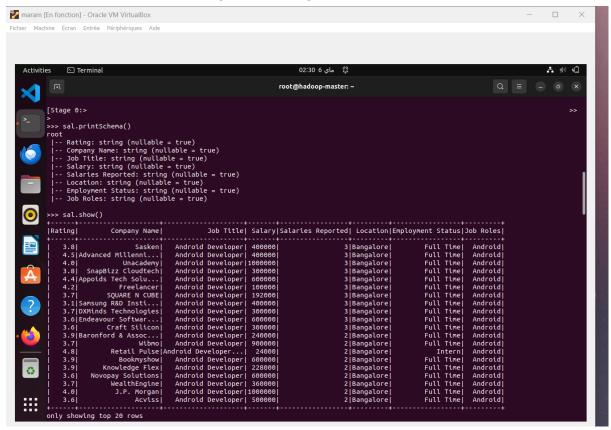
description: Cette commande affiche le schéma des données du DataFrame sal, montrant les noms des colonnes et leurs types.



3. Afficher les premières lignes du DataFrame :

sal.show()

description: Cela affiche les premières lignes du DataFrame sal.

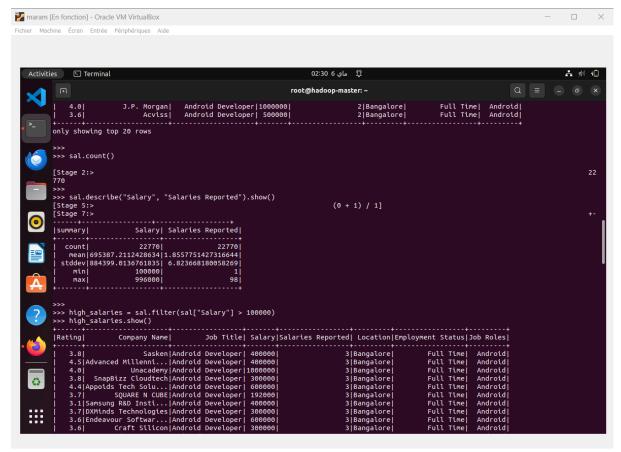


4. Compter le nombre total de lignes dans le DataFrame :

sal.count()

description: Cette commande compte le nombre total de lignes dans le DataFrame

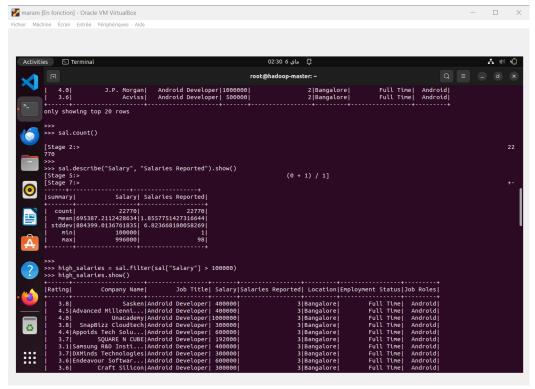
sal.



5. Afficher des statistiques descriptives pour les colonnes "Salary" et "Salaries Reported" :

sal.describe("Salary", "Salaries Reported").show()

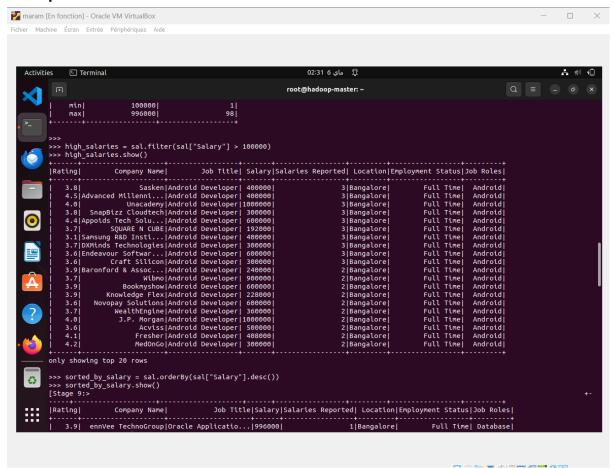
description: Cela affiche des statistiques descriptives telles que la moyenne, l'écart type, le minimum, le maximum, etc., pour les colonnes spécifiées.



6. Filtrer les lignes avec un salaire supérieur à 100 000 :

high_salaries = sal.filter(sal["Salary"] > 100000)
high_salaries.show()

description: Cela filtre les lignes du DataFrame où la valeur de la colonne "Salary" est supérieure à 100 000 et affiche le résultat.



7. Calculer le salaire moyen par entreprise :

```
avg_salary_by_company = sal.groupBy("Company Name").avg("Salary")
avg salary by company.show()
```

description: Cela regroupe les données par entreprise et calcule la moyenne du salaire pour chaque entreprise, puis affiche le résultat.

8. Trier le DataFrame par salaire décroissant :

```
sorted_by_salary = sal.orderBy(sal["Salary"].desc())
sorted_by_salary.show()
```

description: Cela trie le DataFrame en fonction de la colonne "Salary" de manière décroissante et affiche le résultat.

